

인공지능 데이터 전처리 결과서

목차

1. 프로젝트 개요
 - 전처리 목적
 - 데이터 구조 설명
2. 원본 데이터 설명
 - 데이터 출처
 - 변수 설명
 - 데이터 크기
3. 결측치 및 이상치 처리
 - 변수별 처리 방법
4. 데이터 변환
 - 범주형 인코딩 (Label / One-hot)
 - 날짜 데이터 처리
5. Feature Engineering
 - 파생 변수 생성 (예: lead_time, rain_group 등)
 - 제거된 변수
6. 최종 전처리 데이터 구조
 - 최종 feature 리스트
 - shape

1. 프로젝트 개요

전처리 목적

- 호텔 예약 데이터의 노이즈를 제거하고, 도메인 지식 기반의 파생 변수를 생성하여 '예약 취소 예측 모델'의 성능 및 해석력 극대화

데이터 구조 설명

- 호텔 유형(City/Resort), 고객 인원 구성, 예약 시점, 객실 종류, 에이전트 정보 등 예약 행태와 관련된 수치형 및 범주형 변수가 혼합된 구조
-

2. 원본 데이터 설명

데이터 출처

- 포르투갈 지역 호텔의 예약/취소 이력을 담은 원시 데이터

변수 설명

- 예약 리드 타임, 숙박 일수, 고객 정보(인원, 국적), 예약 경로, 객실 유형, 과거 취소 이력, 최종 요금(ADR) 및 취소 여부(is_canceled) 등으로 구성

데이터 크기

- 관측치 수: 119,390 행 (Entries)
- 변수 수: 32 열 (Columns)

3. 결측치 및 이상치 처리

[기본 전제]

- 데이터 무결성: 데이터 수집 시 누락된 값 없이 수집되었음이 명시됨
- 해당 없음 판단: 간혹 누락된 값이 존재할 경우, 이는 데이터 오류가 아닌 '해당사항 없음'으로 간주하여 처리함

변수별 처리 방법

- **children**: 동반 미성년자가 없는 것으로 판단하여 0으로 대체
- **agent** / **company**: 여행사나 대리 회사를 거치지 않은 개인 예약으로 간주하여 신규 코드 0 부여
- **country**: 본국(포르투갈)으로 예상되나 데이터 불확실성 제거를 위해 결측치 행 삭제(Drop)

4. 데이터 변환

범주형 인코딩 (Label / One-hot)

- 이진화(Binary Encoding)
 - **hotel**: unique 값이 2개 존재, 'Resort Hotel' $\rightarrow$ 1, 'City Hotel' $\rightarrow$ 0
 - **agent**, **company**: ID 값 대신 대행 여부만 식별하도록 1, 0 반환
- 재범주화(Regrouping)
 - **country**: 백 수식 개의 국가 코드를 단순화하기 위해 자국인 포르투갈(**PRT**), 포르투갈 외 유럽(**EUR**), 그 외 대륙(**OTH**) 3개 카테고리

날짜 데이터 처리

- **arrival_date_year**, **arrival_date_week_number**, **arrival_date_day_of_month**: 차원 축소를 위해 제거
- **arrival_date_month**: 계절성을 반영하는 인자로 판단하여 유지

5. Feature Engineering

파생 변수 생성

- `guest_type`: `adults`, `children`, `babies` 조합
 - `Family`: 성인 ≥ 1 명 + 아동 또는 유아 ≥ 1 명
 - `Single`: 1명만으로 구성
 - `Group`: 그 외 조합 (예: 성인만 2명 이상 등)
 - `Undefined`: 인원 정보가 모두 0인 경우
- `diff_reserved_room_type`: `reserved_room_type` 과 `assigned_room_type` 비교
 - `1`: 예약한 방과 실제 배정받은 방이 다른 경우 (업/다운그레이드 변동 발생)
 - `0`: 예약한 방과 배정받은 방이 일치하는 경우

제거된 변수

- 필요하지 않은 변수: `arrival_date_year`, `arrival_date_week_number`, `arrival_date_day_of_month`
- 파생 변수 변환 후 원본 삭제: `hotel`, `reserved_room_type`, `assigned_room_type`, `agent`, `company`
- 데이터 누수(Data Leakage) 방지: `reservation_status`, `reservation_status_date`

7. 최종 전처리 데이터 구조

최종 feature 리스트

번호	컬럼명	데이터 타입	설명	변환 유형
1	<code>is_canceled</code>	int64	예약 취소 여부 (1: 취소됨, 0: 취소 안 됨) ※ Target 변수	원본
2	<code>lead_time</code>	int64	PMS 예약 입력일과 도착일 사이의 경과 일수	원본
3	<code>arrival_date_month</code>	str	도착일 - 월 (계절성 반영 인자)	원본
4	<code>stays_in_weekend_nights</code>	int64	주말(토/일) 숙박 또는 예약 일수	원본
5	<code>stays_in_week_nights</code>	int64	평일(월~금) 숙박 또는 예약 일수	원본
6	<code>meal</code>	str	예약한 식사 종류 패키지 코드 (BB, HB, FB, SC, Undefined)	원본
7	<code>market_segment</code>	str	시장 부문 명칭 (예: TA/TO 등 여	원본

번호	컬럼명	데이터 타입	설명	변환 유형
			행사 및 운영업체 분류)	
8	distribution_channel	str	예약 유통 채널 명칭	원본
9	is_repeated_guest	int64	재방문 고객 여부 (1: 재방문, 0: 첫 방문)	원본
10	previous_cancellations	int64	현재 예약 이전 고객이 취소했던 예약 건수	원본
11	previous_bookings_not_canceled	int64	현재 예약 이전 고객이 취소하지 않고 투숙한 횟수	원본
12	booking_changes	int64	예약 입력 후 체크인/취소 전까지의 예약 변경 횟수	원본
13	deposit_type	str	보증금 납부 방식 유형 (보증금 없음, 환불 불가, 환불 가능)	원본
14	days_in_waiting_list	int64	예약 확정 전까지 대기자 명단 (Waiting List)에 있었던 일수	원본
15	customer_type	str	예약 유형 분류 (계약, 그룹, 개별, 일시적 예약 등)	원본
16	adr	float64	일일 평균 요금 (Average Daily Rate)	원본
17	required_car_parking_spaces	int64	고객이 요구한 주차 공간 수	원본
18	total_of_special_requests	int64	고객이 요청한 특별 요구사항 총 개수	원본
19	guest_type	str	투숙객 구성 형태 (Single, Family, Group, Undefined)	신규
20	diff_reserved_room_type	int64	예약한 방과 실제 배정 방의 상이 여부 (1: 변경됨, 0: 동일)	신규
21	is_agent	int64	여행사(Agent)를 경유한 예약 여부	이진화

번호	컬럼명	데이터 타입	설명	변환 유형
			(1: 경유, 0: 직접 예약)	
22	is_company	int64	기업/기관 (Company)을 통한 예약 여부 (1: 기업, 0: 개인)	이진화
23	is_city_hotel	int64	시티 호텔 여부 (1: City Hotel, 0: Resort Hotel)	이진화
24	country_region	str	국적 대그룹 범주 (PRT: 자국, EUR: 유럽, OTH: 비유럽)	범주 재조정

shape

- 행(Rows): 118,902개
- 열(Columns): 24개