

1. 인공지능 데이터 전처리 결과서 (Preprocessing Report)

목차

- 프로젝트 개요
 - 전처리 목적
 - 데이터 구조 설명
- 원본 데이터 설명
 - 데이터 출처
 - 변수 설명
 - 데이터 크기
- 결측치 및 이상치 처리
 - 변수별 처리 방법
- 데이터 변환
 - 범주형 인코딩 (Label / One-hot)
 - 날짜 데이터 처리
- Feature Engineering
 - 파생 변수 생성 (예: lead_time, rain_group 등)
 - 제거된 변수
- 최종 전처리 데이터 구조
 - 최종 feature 리스트
 - shape

1. 프로젝트 개요

전처리 목적

- 호텔 예약 데이터의 노이즈를 제거하고, 도메인 지식 기반의 파생 변수를 생성하여 '예약 취소 예측 모델'의 성능 및 해석력 극대화

데이터 구조 설명

- 호텔 유형(City/Resort), 고객 인원 구성, 예약 시점, 객실 종류, 에이전트 정보 등 예약 행태와 관련된 수치형 및 범주형 변수가 혼합된 구조

2. 원본 데이터 설명

데이터 출처

- 포르투갈 지역 호텔의 예약/취소 이력을 담은 원시 데이터

변수 설명

- 예약 리드 타임, 숙박 일수, 고객 정보(인원, 국적), 예약 경로, 객실 유형, 과거 취소 이력, 최종 요금(ADR) 및 취소 여부(is_canceled) 등으로 구성

데이터 크기

- 관측치 수: 119,390 행 (Entries)

- 변수 수: 32 열 (Columns)

3. 결측치 및 이상치 처리

[기본 전제]

- 데이터 무결성: 데이터 수집 시 누락된 값 없이 수집되었음이 명시됨
- 해당 없음 판단: 간혹 누락된 값이 존재할 경우, 이는 데이터 오류가 아닌 '해당사항 없음'으로 간주하여 처리함

변수별 처리 방법

- **children**: 동반 미성년자가 없는 것으로 판단하여 0으로 대체
- **agent / company**: 여행사나 대리 회사를 거치지 않은 개인 예약으로 간주하여 신규 코드 0 부여
- **country**: 본국(포르투갈)으로 예상되나 데이터 불확실성 제거를 위해 결측치 행 삭제(Drop)

4. 데이터 변환

범주형 인코딩 (Label / One-hot)

- 이진화(Binary Encoding)
 - hotel: unique 값이 2개 존재, 'Resort Hotel' → 1, 'City Hotel' → 0
 - agent, company: ID 값 대신 대행 여부만 식별하도록 1, 0 반환
- 재범주화(Regrouping)
 - **country**: 백 수식 개의 국가 코드를 단순화하기 위해 자국인 포르투갈(PRT), 포르투갈 외 유럽(EUR), 그 외 대륙(OTH) 3개 카테고리로 ### 날짜 데이터 처리
- **arrival_date_year, arrival_date_week_number, arrival_date_day_of_month**: 차원 축소를 위해 제거
- **arrival_date_month**: 계절성을 반영하는 인자로 판단하여 유지

5. Feature Engineering

파생 변수 생성

- **guest_type**: adults, children, babies 조합
 - Family: 성인 ≥ 1명 + 아동 또는 유아 ≥ 1명
 - Single: 1명으로만 구성
 - Group: 그 외 조합 (예: 성인만 2명 이상 등)
 - Undefined: 인원 정보가 모두 0인 경우
- **diff_reserved_room_type**: reserved_room_type과 assigned_room_type 비교
 - 1: 예약한 방과 실제 배정받은 방이 다른 경우 (업/다운그레이드 변동 발생)
 - 0: 예약한 방과 배정받은 방이 일치하는 경우 ### 제거된 변수
- 필요하지 않은 변수: arrival_date_year, arrival_date_week_number, arrival_date_day_of_month
- 파생 변수 변환 후 원본 삭제: hotel, reserved_room_type, assigned_room_type, agent, company
- 데이터 누수(Data Leakage) 방지: reservation_status, reservation_status_date

7. 최종 전처리 데이터 구조

최종 feature 리스트

번호	컬럼명	데이터 타입	설명	변환 유형
1	is_canceled	int64	예약 취소 여부 (1: 취소됨, 0: 취소 안 됨) ※ Target 변수	원본
2	lead_time	int64	PMS 예약 입력일과 도착일 사이의 경과 일수	원본
3	arrival_date_month	str	도착일 - 월 (계절성 반영 인자)	원본
4	stays_in_weekend_nights	int64	주말(토/일) 숙박 또는 예약 일수	원본
5	stays_in_week_nights	int64	평일(월~금) 숙박 또는 예약 일수	원본
6	meal	str	예약한 식사 종류 패키지 코드 (BB, HB, FB, SC, Undefined)	원본
7	market_segment	str	시장 부문 명칭 (예: TA/TO 등 여행사 및 운영업체 분류)	원본
8	distribution_channel	str	예약 유통 채널 명칭	원본
9	is_repeated_guest	int64	재방문 고객 여부 (1: 재방문, 0: 첫 방문)	원본
10	previous_cancellations	int64	현재 예약 이전 고객이 취소했던 예약 건수	원본
11	previous_bookings_not_canceled	int64	현재 예약 이전 고객이 취소하지 않고 투숙한 횟수	원본
12	booking_changes	int64	예약 입력 후 체크인/취소 전까지의 예약 변경 횟수	원본
13	deposit_type	str	보증금 납부 방식 유형 (보증금 없음, 환불 불가, 환불 가능)	원본
14	days_in_waiting_list	int64	예약 확정 전까지 대기자 명단 (Waiting List)에 있었던 일수	원본
15	customer_type	str	예약 유형 분류 (계약, 그룹, 개별, 일시적 예약 등)	원본

번호	컬럼명	데이터 타입	설명	변환 유형
16	adr	float64	일일 평균 요금 (Average Daily Rate)	원본
17	required_car_parking_spaces	int64	고객이 요구한 주차 공간 수	원본
18	total_of_special_requests	int64	고객이 요청한 특별 요구사항 총 개수	원본
19	guest_type	str	투숙객 구성 형태 (Single, Family, Group, Undefined)	신규
20	diff_reserved_room_type	int64	예약한 방과 실제 배정 방의 상이 여 부 (1: 변경됨, 0: 동 일)	신규
21	is_agent	int64	여행사(Agent)를 경유한 예약 여부 (1: 경유, 0: 직접 예 약)	이진화
22	is_company	int64	기업/기관 (Company)을 통한 예약 여부 (1: 기업, 0: 개인)	이진화
23	is_city_hotel	int64	시티 호텔 여부 (1: City Hotel, 0: Resort Hotel)	이진화
24	country_region	str	국적 대그룹 범주 (PRT: 자국, EUR: 유럽, OTH: 비유럽)	범주 재조정

shape

- 행(Rows): 118,902개
- 열(Columns): 24개